

## 2.1. Байесовская классификация

$Y$  – зависимая категориальная переменная,  $D_Y = \{\omega_1, \dots, \omega_K\}$ ,

$\omega_l$  -  $l$ -й класс ( $D_Y = \{1, \dots, \omega, \dots, K\}$ );  $D_X = R^n$

Необходимо разработать классификатор, оптимальный по некоторому критерию:

$$x = X(a) \in D_X: \quad x \xrightarrow{f} \omega.$$

Критерий качества, например, - риск ошибочной классификации

$f$  - называется решающей функцией или классификатором.

Пусть дано распределение  $P(x, y)$ . По правилу условной вероятности

$$P(x, y) = P(y)P(x | y) = P(x)P(y | x),$$

где

$P(y) = P(Y(a) = \omega) = P(\omega)$  - это априорная вероятность класса  $\omega$ ,

$P(x | y) = P_{\omega}(x)$  - это условное распределение переменной для класса  $\omega$  (функция правдоподобия класса)

$P(y | x) = P(Y(a) = \omega | X(a) = x) = P_x(\omega)$  - это вероятность класса  $\omega$  для точки  $x$  (апостериорная вероятность класса),

$$\sum_{\omega=1}^K P(\omega) = 1, \quad \sum_{\omega=1}^K P_x(\omega) = 1$$

## Байесовская решающая функция

$$f_B : x \rightarrow \omega^* : \omega^* = \arg \max_{\omega} P_x(\omega)$$

- максимизирует апостериорную вероятность класса.

По формуле Байеса: 
$$P_x(\omega) = \frac{P(\omega)P_{\omega}(x)}{P(x)},$$

где  $P(x) = \sum_{\omega=1}^K P(\omega)P_{\omega}(x)$  (по правилу полной вероятности).

Тогда, 
$$\omega^* = \arg \max_{\omega} P(\omega)P_{\omega}(x).$$

*Например, для  $K=2$ :*  $f_B$  соответствует разбиению

$$D_{X,f_B}^{(1)} = \{x \mid P(1)P_1(x) \geq P(2)P_2(x)\}, \quad D_{X,f_B}^{(2)} = \overline{D_{X,f_B}^{(1)}}$$

Теорема. Для Байесовской решающей функции вероятность ошибки является минимальной


Доказательство. ( $K=2$ )

Пусть  $f$  произвольная решающая функция. Тогда

$$\begin{aligned} P_f^{err} &= P(1) \int_{x \in D_{X,f}^{(2)}} p_1(x) dx + P(2) \int_{x \in D_{X,f}^{(1)}} p_2(x) dx = \\ &= \int_{D_X} h(x, f(x)) dx, \end{aligned}$$

где

$$h(x, f(x)) = \begin{cases} P(1)p_1(x) & \text{for } x \in D_{X,f}^{(2)}, \\ P(2)p_2(x) & \text{for } x \in D_{X,f}^{(1)}. \end{cases}$$



Ошибка минимальна, если

$$P(1)p_1(x) < P(2)p_2(x) \text{ for } x \in D_{X,f}^{(2)}$$

$$P(1)p_1(x) > P(2)p_2(x) \text{ for } x \in D_{X,f}^{(1)}.$$

$\Rightarrow$   $x$  относится к классу с максимальным значением

$P(\omega)p_\omega(x) = P_x(\omega) \cdot P(x) \Rightarrow f$  это Байесовская решающая функция.

# Оптимальная разделяющая функция

Пусть  $K=2$ ,  $f_B$  это Байесовская решающая функция:

$$D_{X,f_B}^{(1)} = \{x \mid P(1)P_1(x) \geq P(2)P_2(x)\}, \quad D_{X,f_B}^{(2)} = \overline{D_{X,f_B}^{(1)}}.$$

$$L = \{x \mid P(1)P_1(x) = P(2)P_2(x)\}.$$

$$P(1)P_1(x) = P(2)P_2(x)$$

$$\frac{P(1)P_1(x)}{P(2)P_2(x)} = 1,$$

Тогда

$$l_0(x) = \log \frac{P_1(x)}{P_2(x)} + \log \frac{P(1)}{P(2)} = 0.$$

Функция, определяемая уравнением  $l_0(x) = 0$  называется оптимальной разделяющей функцией.

# Оценивание распределения по выборке

На практике распределение вероятностей неизвестно и должно оцениваться по обучающей выборке.

Оценка априорной вероятности класса:

$$\hat{P}(\omega) = N(\omega) / N,$$

где  $N(\omega)$  это число объектов класса  $\omega$  в таблице данных,

$$N = \sum_{\omega=1}^k N(\omega).$$

По закону больших чисел:  $\hat{P}(\omega) \xrightarrow[p]{} P(\omega)$  при  $N(\omega) \rightarrow \infty$

Как оценить априорное распределение переменной  $P_{\omega}(x)$  ?

**Параметрический подход:** предполагается общая форма распределения  $P_{\omega}(x)$  как функция с неизвестными параметрами


$$P_{\omega}(x) = \varphi(x, \theta);$$

или

$$P_{\omega}(x) = \sum_{l=1}^L w_l \varphi_l(x, \theta_l)$$

(модель смеси распределений).

**Непараметрический:**  $\hat{p}_{\omega}(x) = \frac{1}{Nh^n} \sum_{i=1}^N \phi\left(\frac{x - x^{(i)}}{h}\right)$





# Оценивание параметров

Пусть класс  $\omega$  фиксирован. Предположим, что

$$P(x) = \varphi(x, \theta),$$

где  $\theta \in \Theta$ ,  $\theta = (\theta_1, \dots, \theta_m)$ .

Для нахождения оценки  $\hat{\theta}$  используется, например, метод максимального правдоподобия.

Логарифмическая функция правдоподобия:

$$L(\theta) = \log \prod_i P(x^{(i)}) = \sum_i \log(\varphi(x^{(i)}, \theta)); \quad (\log \leftrightarrow \ln).$$

Оценка МП  $\theta^* : L(\theta^*) = \max_{\theta} L(\theta)$ .

Необходимое условие экстремума:

$$\frac{\partial}{\partial \theta_l} L(\theta_1, \dots, \theta_m) = \sum_i \frac{\partial}{\partial \theta_l} \log(\varphi(x^{(i)}, \theta_1, \dots, \theta_m)) = 0, \quad l = 1, \dots, m$$

(система  $m$  уравнений;  $m$  - число неизвестных параметров)


→ наилучший вектор  $\theta^* = (\theta_1^*, \dots, \theta_m^*)$ .

## Пример: 2 класса, 1 переменная, нормальное распределение

Предположим нормальное распределение для каждого класса:

$$\omega_1 : p_1(x) \sim N(\mu_1, \sigma_1); \quad \omega_2 : p_2(x) \sim N(\mu_2, \sigma_2);$$

априорные вероятности  $P(1), P(2)$  ( $P(1)+P(2)=1$ ).



$$p_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} e^{-\frac{(x-\mu_k)^2}{2\sigma_k^2}}, \quad k = 1, 2.$$

Разделяющая функция (дискриминант):

$$l_0(x) = \ln \frac{p_1(x)}{p_2(x)} + \ln \frac{P(1)}{P(2)} = 0;$$


$$\ln \left( \frac{e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}}{\sqrt{2\pi}\sigma_1} / \frac{e^{-\frac{(x-\mu_2)^2}{2\sigma_2^2}}}{\sqrt{2\pi}\sigma_2} \right) + \ln \frac{P(1)}{P(2)} = 0;$$

$$\ln \frac{\sigma_2}{\sigma_1} + \left( -\frac{(x-\mu_1)^2}{2\sigma_1^2} + \frac{(x-\mu_2)^2}{2\sigma_2^2} \right) + \ln \frac{P(1)}{P(2)} = 0;$$


$$\frac{(x-\mu_2)^2}{\sigma_2^2} - \frac{(x-\mu_1)^2}{\sigma_1^2} = 2 \ln \left( \frac{P(2)}{P(1)} \frac{\sigma_1}{\sigma_2} \right)$$

- квадратное уравнение


а) один корень  $x^*$  :



б) два корня  $x_1^*, x_2^*$  :



в) нет корней



Подставим вместо параметров из оценки в  $l_0(x)$ :

$$\hat{P}(1) = \frac{N(1)}{N}, \hat{P}(2) = \frac{N(2)}{N},$$

Теорема. Для нормального распределения оценки максимального правдоподобия равны:

$$\hat{\mu}_1 = \frac{1}{N(1)} \sum_{i:Y(i)=1} x^{(i)}, \hat{\mu}_2 = \frac{1}{N(2)} \sum_{i:Y(i)=2} x^{(i)},$$

$$\hat{\sigma}_1^2 = \frac{1}{N(1)} \sum_{i:Y(i)=1} (x^{(i)} - \hat{\mu}_1)^2, \hat{\sigma}_2^2 = \frac{1}{N(2)} \sum_{i:Y(i)=2} (x^{(i)} - \hat{\mu}_2)^2$$

Пример: 2 класса, 2 переменные  $X_1, X_2$ ,  
нормальное распределение

Нормальное распределение

$$p_1(x_1, x_2) = \frac{1}{2\pi |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right),$$

где  $\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{pmatrix}$  - ковариационная матрица,

$\sigma_{ij} = \mathbf{E}[(X_i - \mu_i)(X_j - \mu_j)]$ ,  $\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$  центроид первого  
класса,

$$p_2(x_1, x_2) = \frac{1}{2\pi |\Lambda|^{1/2}} \exp\left(-\frac{1}{2}(x - \nu)^T \Lambda^{-1}(x - \nu)\right),$$

где  $\Lambda = \begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{12} & \lambda_{22} \end{pmatrix}$  это ковариационная матрица,

$\lambda_{ij} = \mathbf{E}[(X_i - \nu_i)(X_j - \nu_j)]$ ,  $\nu = \begin{pmatrix} \nu_1 \\ \nu_2 \end{pmatrix}$  это центроид

второго класса.

Для нахождения оптимальной разделяющей функции решим уравнение

$$p_1(x_1, x_2)P(1) = p_2(x_1, x_2)P(2) .$$

Случай 1: независимые переменные и одинаковые дисперсии для каждого класса:

$$\Sigma = \Lambda = \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix}, \text{ then}$$


$$P(1) \exp \left\{ -\frac{1}{2\sigma^2} \left[ (x_1 - \mu_1)^2 + (x_2 - \mu_2)^2 \right] \right\} =$$

$$= P(2) \exp \left\{ -\frac{1}{2\sigma^2} \left[ (x_1 - \nu_1)^2 + (x_2 - \nu_2)^2 \right] \right\} \Rightarrow$$

$$x_2 = \frac{\mu_1 - \nu_1}{\nu_2 - \mu_2} x_1 + \left( \frac{\nu_1^2 + \nu_2^2 - \mu_1^2 - \mu_2^2}{2(\nu_2 - \mu_2)} - \frac{\sigma^2}{\nu_2 - \mu_2} \ln \frac{P(2)}{P(1)} \right)$$

ИЛИ  $x_2 = a x_1 + b.$






Поскольку параметры неизвестны, они оцениваются по выборке.


Случай 2. Пусть  $\Sigma$ ,  $\Lambda$  произвольные,  $\Sigma = \Lambda$ . Тогда получаем линейную разделяющую функцию (Линейный дискриминант Фишера):

$$w_1 x_1 + w_2 x_2 = w_1 x_{01} + w_2 x_{02},$$

where  $\begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \Sigma^{-1}(\mu - \nu)$ ,  $\begin{pmatrix} x_{01} \\ x_{02} \end{pmatrix} = \frac{1}{2}(\mu + \nu) - \frac{\ln P(1) - \ln P(2)}{(\mu - \nu)^T \Sigma^{-1}(\mu - \nu)}$



**Случай 3. Для произвольных ковариационных матриц** разделяющая функция - это кривая второго порядка (парабола, эллипс, окружность, прямая линия, гипербола)



$$l_0(x) = \frac{1}{2} [Q_2(x) - Q_1(x)] + \ln \frac{|\Lambda|^{1/2}}{|\Sigma|^{1/2}} + \ln \frac{P(1)}{P(2)} = 0,$$

где  $Q_1, Q_2$  квадратичные формы,  $Q_1 = (x - \mu)^T \Sigma^{-1} (x - \mu)$ ,  
 $Q_2 = (x - \nu)^T \Lambda^{-1} (x - \nu)$  - **квадратичный дискриминант**.

Таким образом, предположение о нормальном распределении приводит к

**линейной разделяющей функции** (для одинаковых ковариационных матриц),

или

**квадратичной разделяющей функции**  
(для произвольных ковариационных матриц).

**Двойственный подход:** определим семейство линейных или квадратичных разделяющих функций и найдем оптимальную функцию в этом семействе.

Оба этих подхода эквивалентны.

# Байесовская классификация в случае дискретных переменных

## 1. Наивный Байесовский классификатор

Рассмотрим случай произвольных категориальных переменных  $X_1, \dots, X_j, \dots, X_n$ . Пусть  $D_j = \{u_{1,j}, \dots, u_{l_j,j}\}$ ,  $l_j \geq 2$ . Предположим, что все переменные **независимы**.

Тогда  $x_j \in \{u_{1,j}, \dots, u_{l_j,j}\}$ :

$$P_{\omega}(x) = P_{\omega}(x_1) \cdot \dots \cdot P_{\omega}(x_j) \cdot \dots \cdot P_{\omega}(x_n), \quad \omega = 1, \dots, K.$$

Байесовская решающая функция:

$$x \rightarrow \omega^* : \omega^* = \arg \max_{\omega} P(\omega) P_{\omega}(x_1) \cdot \dots \cdot P_{\omega}(x_n).$$

Оценки вероятностей:

$$\hat{P}_{\omega}(x_j) = \frac{N_{\omega}(X_j = x_j)}{N(\omega)}, \quad \hat{P}(\omega) = \frac{N(\omega)}{N},$$

где  $N_{\omega}(X_j = x_j)$  - число объектов класса  $\omega$ , для которых  $X_j$  принимает значение  $x_j$ .

## 2. Бинарный классификатор, $K = 2$

$$X = \{X_1, \dots, X_j, \dots, X_n\}, D_j = \{0, 1\}$$

Обозначим:

$$P_1(x_j = 1) = p_j;$$

Тогда  $P_1(x_j = 0) = 1 - p_j$ .

$$q_j = P_2(x_j = 1);$$

Тогда  $P_2(x_j = 0) = 1 - q_j$ .

В результате получим

$$P_1(x_j) = p_j^{x_j} (1 - p_j)^{1-x_j};$$

$$P_2(x_j) = q_j^{x_j} (1 - q_j)^{1-x_j}.$$

$$\begin{aligned}
l_0(x) &= \log \frac{P_1(x)}{P_2(x)} + \log \frac{P(1)}{P(2)} = \\
&= \sum_{j=1}^n \log [p_j^{x_j} (1-p_j)^{1-x_j}] - \sum_{j=1}^n \log [q_j^{x_j} (1-q_j)^{1-x_j}] + \log \frac{P(1)}{P(2)} = \\
&= \sum_{j=1}^n \left[ x_j \log \frac{p_j(1-q_j)}{q_j(1-p_j)} \right] + \sum_{j=1}^n \log \frac{1-p_j}{1-q_j} + \log \frac{P(1)}{P(2)} = \\
&= \sum_{j=1}^n b_j x_j + b_0 = 0
\end{aligned}$$

тогда  $b_j = \log \frac{p_j(1-q_j)}{q_j(1-p_j)}$ ,  $b_0 = \sum_{j=1}^n \log \frac{1-p_j}{1-q_j} + \log \frac{P(1)}{P(2)}$ .

$l_0(x) = 0$  - уравнение гиперплоскости в  $D_X$ .

Оптимальное разбиение  $\beta_0 = \{D_X^{(1)}, D_X^{(2)}\}$ , где  $D_X^{(1)} = \{x | l_0(x) \geq 0\}$ ,  
 $D_X^{(2)} = \overline{D_X^{(1)}}$ .



Разделяющая функция (дискриминант):

$$\hat{l}_0(x) = \sum_{j=1}^n \hat{b}_j x_j + \hat{b}_0 = 0,$$

где  $\hat{b}_j = \log \frac{\hat{p}_j(1 - \hat{q}_j)}{\hat{q}_j(1 - \hat{p}_j)}$ ,  $\hat{b}_0 = \sum_{j=1}^n \log \frac{1 - \hat{p}_j}{1 - \hat{q}_j} + \log \frac{\hat{P}(1)}{\hat{P}(2)}$ .

оценки  $\hat{P}(1) = \frac{N(1)}{N}$ ,  $\hat{P}(2) = \frac{N(2)}{N}$ ,

$$\hat{p}_j = \frac{N_1(x_j = 1)}{N(1)}, \quad \hat{q}_j = \frac{N_2(x_j = 1)}{N(2)},$$

или Байсовские оценки <sup>\*</sup>:

$$\hat{p}_j = \frac{N_1(x_j = 1) + 1}{N(1) + 2}, \quad \hat{q}_j = \frac{N_2(x_j = 1) + 1}{N(2) + 2},$$

где  $N(1)$ ,  $N(2)$  - число объектов первого и второго класса ( $N = N(1) + N(2)$ ),  $N_1(x_j = 1)$ ,  $N_2(x_j = 1)$  - число объектов первого и второго класса, для которых  $x_j$  принимает значение 1.

---

Borovkov A. A. On the Problem of Pattern Recognition // Theory Probab. Appl. 1971. 16(1), 141–144.

# Непараметрический подход

**Идея:** чтобы классифицировать  $x$ , необходимо оценить апостериорную вероятность только **в этой** точке

Пусть класс  $\omega$  фиксирован. Необходимо найти функцию плотности  $p(x)$ , используя

$$x^{(1)}, \dots, x^{(N)},$$

где  $x^{(i)} = (x_1^{(i)}, \dots, x_n^{(i)}) \in \mathbf{R}^n$ .

Предположим, что  $X^{(1)}, \dots, X^{(N)}$  независимы и одинаково распределены;

$$X^{(i)} \sim p(x).$$

Пусть  $V$  небольшая область около  $x$ ;

$|V|$  - это объем;

$k$  = число точек в  $V$ .

Оценить плотность можно так

$$p_N(x) = \frac{k}{N} / |V_N|$$

Желаемое свойство - состоятельность, т.е.

$$p_N(x) \rightarrow p(x) \text{ когда } N \rightarrow \infty.$$


Есть два способа:

### Окно Парзена


$V_N$  - серия регулярных областей (гиперсфера, гиперкуб),  
объем  $|V_N| = \frac{V_0}{\sqrt{N}}$ , где  $V_0$  это параметр.

2)  $k_N$  ближайших соседей (nearest neighbors):  $k_N = \sqrt{N}$ ;

Размер  $V_N$  растет пока  $V$  не будет включать  $k_N$   
ближайших к  $x$  точек.



Для фиксированного  $N$ , рассмотрим окно Парзена:




$V$  - это  $n$ -мерный гиперкуб с центром в точке  $x$ .

Обозначим  $u = \frac{x - x'}{h}$ , где  $x, x'$  произвольные точки,

$h$  - это длина ребра гиперкуба (размер окна),  $|V| = h^n$ .

Пусть  $\phi(u)$ :  $\phi(u) \geq 0$ ,

$$\int_{x \in D} \phi(u) du = 1, \quad \phi(u) = \begin{cases} 1, & \text{if } |u_j| \leq \frac{1}{2}, j = 1, \dots, n \\ 0, & \text{otherwise} \end{cases}.$$



Число точек, попавших в  $V$ :

$$k = \sum_i \phi\left(\frac{x - x^{(i)}}{h}\right).$$

Оценка функции плотности:  $p_N(x) = \frac{1}{Nh^n} \sum_i \phi\left(\frac{x - x^{(i)}}{h}\right)$



Обобщение: оценка Розенблатта-Парзена:

$$p_N(x) = \frac{1}{Nh^n} \sum_i \phi\left(\frac{\|x^i - x\|}{h}\right),$$


где  $\phi(\cdot)$  - ядерная функция:

- $\phi(r) \geq 0$
- $\phi(\cdot)$  четная функция;
- $\int \phi(r) dr = 1$ ;
- $r > 0$ .

В общем случае ядро это функция  $\phi(x, x')$ .

$$V_N = \frac{|V_1|}{\sqrt{N}} = \frac{h_1^n}{\sqrt{N}}, \text{ где } h_1 \text{ это параметр}$$

## Основные типы ядер:



$E(r) = \frac{3}{4}(1 - r^2)[|r| \leq 1]$  — Epanechnikov kernel;

$Q(r) = \frac{15}{16}(1 - r^2)^2[|r| \leq 1]$  — quartic;

$T(r) = (1 - |r|)[|r| \leq 1]$  — triangular;

$G(r) = (2\pi)^{-1/2} \exp(-\frac{1}{2}r^2)$  — Gauss;

$\Pi(r) = \frac{1}{2}[|r| \leq 1]$  — rectangular;

$$[\mathbf{I}] = \begin{cases} 1, & \mathbf{I} = true \\ 0, & \mathbf{I} = false \end{cases}$$

## Многомерный случай

Ядро Епанечникова:

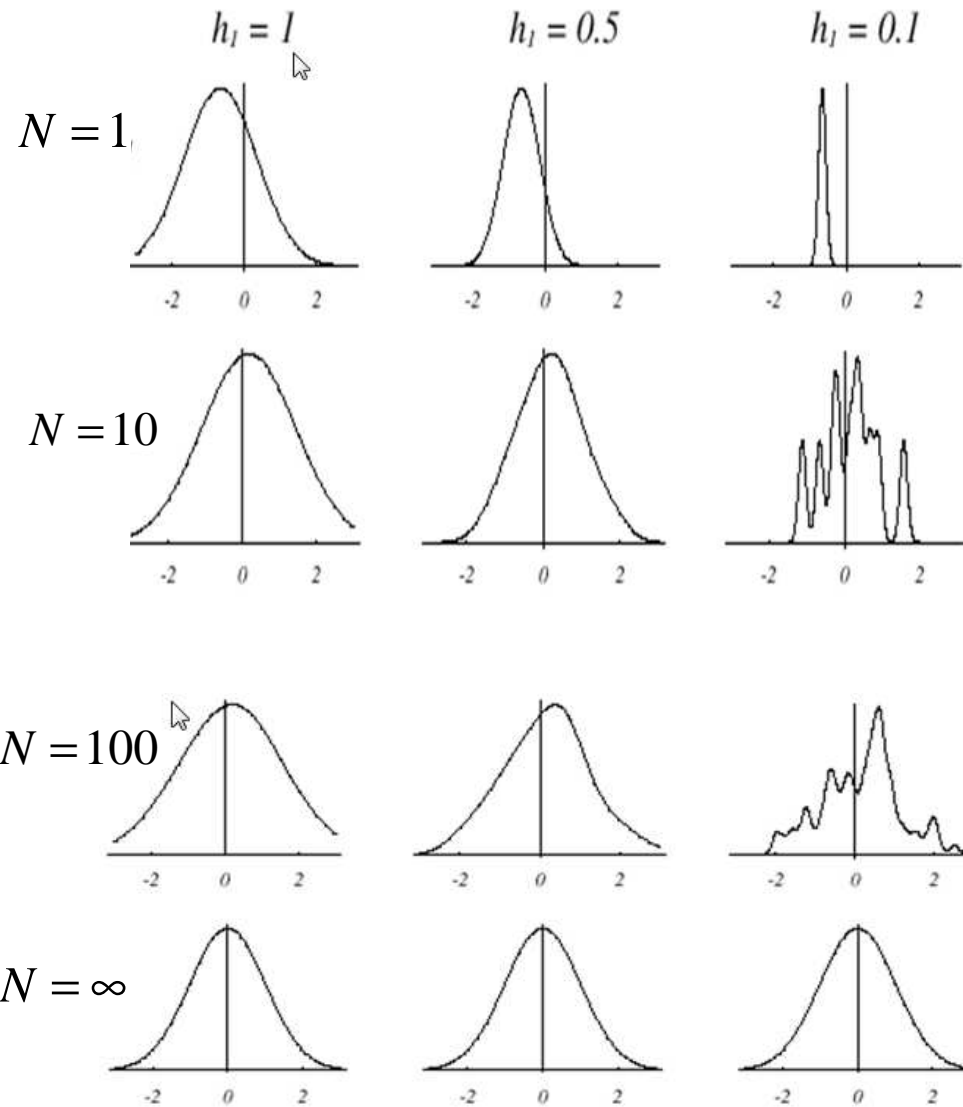
$$\phi_E = \begin{cases} \frac{1}{2} V_n^{-1} (n+2)(1-r^2), & \text{if } r \leq 1, \\ 0, & \text{else,} \end{cases}$$


где  $V_n$  – объем  $n$ -мерной единичной сферы

Многомерное нормальное ядро:

$$\phi_N = (2\pi)^{-n/2} e^{-\frac{r^2}{2}}.$$

## Пример (нормальное ядро)







Оптимальная выборочная разделяющая функция:

$$\begin{aligned}
 \hat{f}_B(x) &= \arg \max_{\omega} \hat{P}(\omega) p_{N,\omega}(x) = \\
 &= \arg \max_{\omega} \frac{N(\omega)}{N} \frac{1}{N(\omega)h^n} \sum_{i: y^{(i)} = \omega} \phi\left(\frac{\|x - x^{(i)}\|}{h}\right) = \\
 &= \arg \max_{\omega} \sum_{i: y^{(i)} = \omega} \phi\left(\frac{\|x - x^{(i)}\|}{h}\right).
 \end{aligned}$$

## Влияние размера окна на решающую функцию




small  $h$



large  $h$


## Недостатки окна Парзена

- для большой размерности  $\rho(x, x')$  может быть существенно отличным от  $\rho(x, x'')$ , где  $x'$  — точка в вершине куба,  $x''$  — точка на ребре куба.



equally dependent on  
density estimation,  
though distances to  
the center  
significantly differ

- для фиксированного объема  $V_N$ , число входящих объектов может существенно отличаться при разных  $x$ .



## Метод $k$ ближайших соседей kNN

Пусть  $V$  зависит от  $x$ :  $V = V_N(x)$ .

Решения для  $x$  зависят от  $k$  ближайших точек:  
размер окна увеличивается пока  $V_N(x)$  не будет содержать  
ровно  $k$  точек из  $N$

$$(k = \sum_{\omega} k^{(\omega)}).$$

Оптимальная решающая функция:

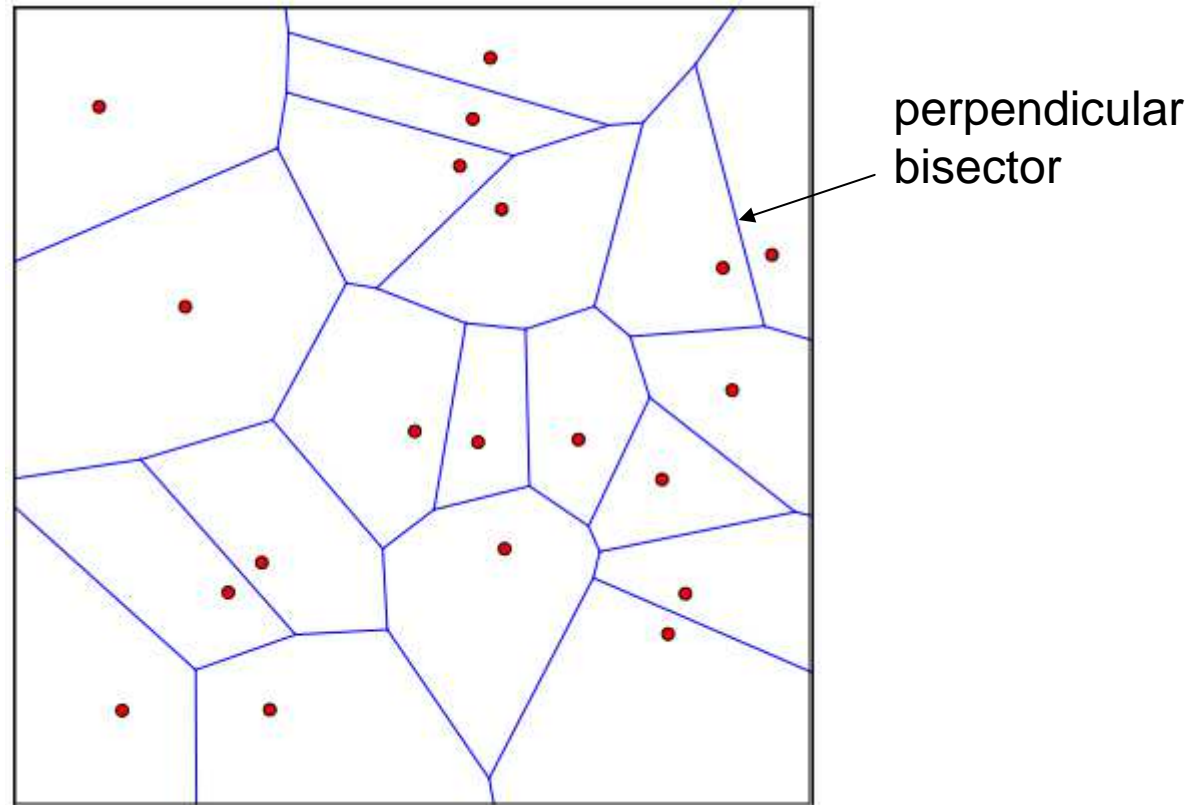
$$\begin{aligned}\hat{f}_B(x) &= \arg \max_{\omega} \hat{P}(\omega) \frac{k^{(\omega)} / N(\omega)}{|V_N|} = \\ &= \arg \max_{\omega} \frac{N(\omega)}{N} \frac{k^{(\omega)}}{N(\omega) |V_N|} = \arg \max_{\omega} k^{(\omega)}.\end{aligned}$$

kNN запоминает все объекты обучающей выборки и затем сравнивает их с точкой  $x$ .




Метод ближайшего соседа ( $k = 1$ ):  
каждой точке  $x \in D$  соответствует класс ближайшей  
точки

### Voronoi diagram



nearest neighbor method



Region that corresponds to each class, is a union of polyhedrons in  $n$ -dimensional variable space

Вероятность ошибки для метода ближайшего соседа (для бинарной классификации)

**Теорема.** Вероятность ошибки для метода ближайшего соседа превосходит вероятность ошибки оптимального байесовского классификатора не более чем в 2 раза при достаточно большом объеме обучающей выборки.